Análisis de datos masivos

Datos del estudiante

Nombre y apellido: Renso Paulino Brazobán Durán

Fecha de entrega: 10 de abril, 2026

Aplicando aprendizaje automático para dar soluciones a los problemas de la empresa

1. Introducción

El objetivo de la presente actividad es realizar un análisis exploratorio y predictivo a partir de una base de datos de clientes y ventas, utilizando Excel como herramienta principal. En el análisis se explora el comportamiento de los clientes, se construyen modelos de proyección de compra de bicicletas y se realiza un pronostico de ventas a futuro. Este trabajo agrupa técnicas descriptivas, modelos de clasificación y herramientas de pronóstico con la finalidad de apoyar la toma de decisiones basadas en datos.

2. Descripción del Dataset

El análisis se llevo a cabo utilizando el archivo DatasetActivity2.xlsx, las hojas principales que se utilizaron son:

- Var Discrete Adq Bicicleta: esta hoja incluye información demográfica y de comportamiento de los clientes, como rango de ingreso anual, edad, números de hijos, vehículos propios y Bikepurchase, variable que indica si el cliente compro o no una bicicleta.
- ST Total Sales: contiene datos históricos de ventas que brindan la posibilidad de analizar el progreso temporal de las ventas y realizar una proyección a futuro.

3. Preparación y limpieza de datos

Antes de llevar a cabo el análisis, se completaron distintos procesos de limpieza de la base datos en Excel, entre ellos:

- Conversión del conjunto de datos en tablas de Excel para facilitar su manipulación.

- Eliminación de variables innecesarias que no aportan valor analítico como country, group y person type.
- Revisión y eliminación de registros duplicados.
- Verificación de valores faltantes.
- Validación de los tipos de datos, comprobando que las variables numéricas y de texto estuvieran correctamente definidas para evitar errores.

4. Análisis descriptivo.

Algunas de las estadísticas descriptivas para las variables numéricas son:

Total Amount

- Media: 1,588.33
- Desviación estándar: 2,124.23
- Mínimo: 2.29
- Máximo: 13,295.38

Total Children:

- Media:1.85
- Desviación estándar: 1.61
- Mínimo: 0
- Máximo: 5

Age

- Media: 58.42
- Desviación estándar: 11.25
- Mínimo: 40
- Máximo: 110

Number Cars Owned

- Media: 1.50
- Desviación estándar: 1.14
- Mínimo: 0
- Máximo: 4

5. Modelo de predicción

Para predecir la compra de bicicletas se utilizó un modelo de clasificación sencillo en Excel utilizando la regresión lineal con variable binaria.

Variable dependiente: Bike Purchase (0 = no compra, 1 = compra).

Variables independientes: age, total children, number cars owned y total amount.

El modelo de predicción fue estimado utilizando la herramienta “Regresión” de Excel, permitiendo obtener valores importantes y el coeficiente de determinación (R^2).

6. Interpretación de resultados

El modelo de regresión permitió evaluar que efecto tienen distintas variables explicativas sobre la probabilidad de compra de una bicicleta, utilizando Bike purchase como variable dependiente binaria.

La variable **Age** presenta un coeficiente estimado de signo +/-, lo que indica que, manteniendo constantes el resto de las variables, un incremento en la edad del cliente aumenta o disminuye la probabilidad estimada de compra. Este efecto resulta significativo o no según el valor-p observado, lo que sugiere que la edad es un factor relevante en la decisión de adquisición.

Por su parte, la variable **TotalChildren** muestra un coeficiente de signo (+/-), evidenciando que el número de hijos en el hogar tiene un impacto directo sobre la probabilidad de compra. Este resultado es consistente con patrones de consumo asociados a estructuras familiares, y su significancia estadística permite evaluar la solidez de dicha relación dentro del modelo.

Asimismo, **NumberCarsOwned** presenta un coeficiente cuyo signo indica que la posesión de vehículos actúa como un indicador del perfil socioeconómico y de las preferencias de movilidad del cliente. Un mayor número de vehículos influye positiva o negativamente en la probabilidad de compra de bicicletas, lo cual puede interpretarse en términos de sustitución o complementariedad entre distintos medios de transporte.

Finalmente, el **coeficiente de determinación R^2** indica que el modelo explica una proporción limitada pero relevante de la variabilidad de la variable dependiente. En ese sentido, el modelo cumple apropiadamente su función exploratoria y predictiva,

permitiendo identificar relaciones direccionales claras entre las variables analizadas y la probabilidad de compra.

7. Pronóstico de ventas

Para el análisis de pronóstico se utilizó la hoja ST Total Sales, la cual contiene el histórico de ventas de la empresa. En primer lugar, se construyó la variable TotalSales mediante la agregación de las ventas individuales, calculando la suma de las columnas correspondientes para cada período. Esta variable permitió consolidar la información y trabajar con una única serie temporal representativa del nivel de ventas.

Luego, se empleo la herramienta “hoja de pronóstico” para estimar el comportamiento futuro de ventas a 60 días y un nivel de confianza de 95%, lo que permitió generar una proyección de ventas junto con sus respectivos intervalos de confianza superior e inferior. El resultado se presentó mediante un gráfico que muestra la evolución histórica de las ventas y la tendencia esperada en el período futuro.

8. Conclusiones

El análisis llevado a cabo permitió identificar patrones importantes en el comportamiento de los consumidores y en la evolución de las ventas. A partir de las estadísticas descriptivas y la tabla dinámica, se observaron diferencias en la compra de bicicletas según características demográficas y de comportamiento. El modelo de regresión aplicado permitió evaluar la influencia de variables como la edad, el número de hijos y la cantidad de vehículos sobre la probabilidad de compra, evidenciando relaciones consistentes con el perfil del cliente.

Asimismo, el pronóstico de ventas proporcionó una estimación razonable del comportamiento futuro, incorporando la incertidumbre inherente mediante intervalos de confianza. En conjunto, los resultados obtenidos demuestran que Excel es una herramienta adecuada para realizar análisis exploratorios, modelos predictivos sencillos y pronósticos, aportando información útil para la toma de decisiones empresariales basadas en datos.

9. Anexos

Estadísticas descriptivas.

TotalAmount	
Media	1588.32922
Error típico	15.6244202
Mediana	270.265
Moda	4.99
Desviación estándar	2124.23172
Varianza de la muestra	4512360.39
Curtosis	1.34467101
Coeficiente de asimetría	1.41032828
Rango	13293.09
Mínimo	2.29
Máximo	13295.38
Suma	29358677.2
Cuenta	18484

TotalChildren (X)	
Media	1.84435187
Error típico	0.01185979
Mediana	2
Moda	0
Desviación estándar	1.61240793
Varianza de la muestra	2.59985935
Curtosis	-0.94703397
Coeficiente de asimetría	0.47287289
Rango	5
Mínimo	0
Máximo	5
Suma	34091
Cuenta	18484

Age (X)	
Media	58.420039
Error típico	0.08274146
Mediana	57
Moda	52
Desviación estándar	11.2491875
Varianza de la muestra	126.54422
Curtosis	-0.1130571
Coeficiente de asimetría	0.57067719
Rango	70
Mínimo	40
Máximo	110
Suma	1079836
Cuenta	18484

NumberCarsOwned (X)	
Media	1.50270504
Error típico	0.00837326
Mediana	2
Moda	2
Desviación estándar	1.13839374
Varianza de la muestra	1.29594031
Curtosis	-0.43438773
Coeficiente de asimetría	0.40176721
Rango	4
Mínimo	0
Máximo	4
Suma	27776
Cuenta	18484

Gráficos

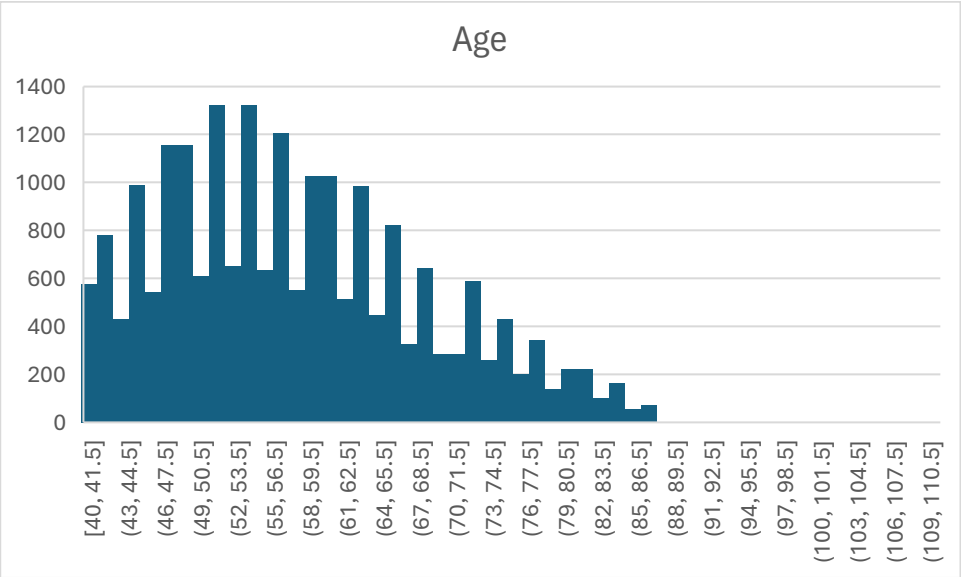

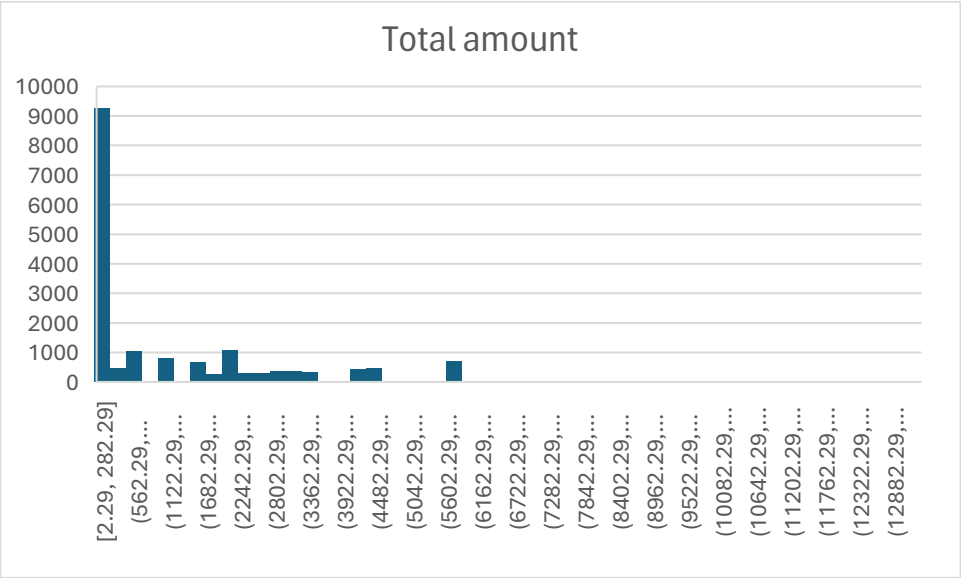

Tabla dinámica

Cuenta de BikePurchase (Y)	Etiquetas de columna			
Etiquetas de fila	**0**	**1**	**(en blanco)**	**Total general**
0-25000	1736	1186		2922
25001-50000	2770	2934		5704
50001-75000	2608	2868		5476
75001-100000	1454	1301		2755
greater than 100000	784	843		1627
(en blanco)				
Total general	**9352**	**9132**		**18484**

Hoja de pronostico

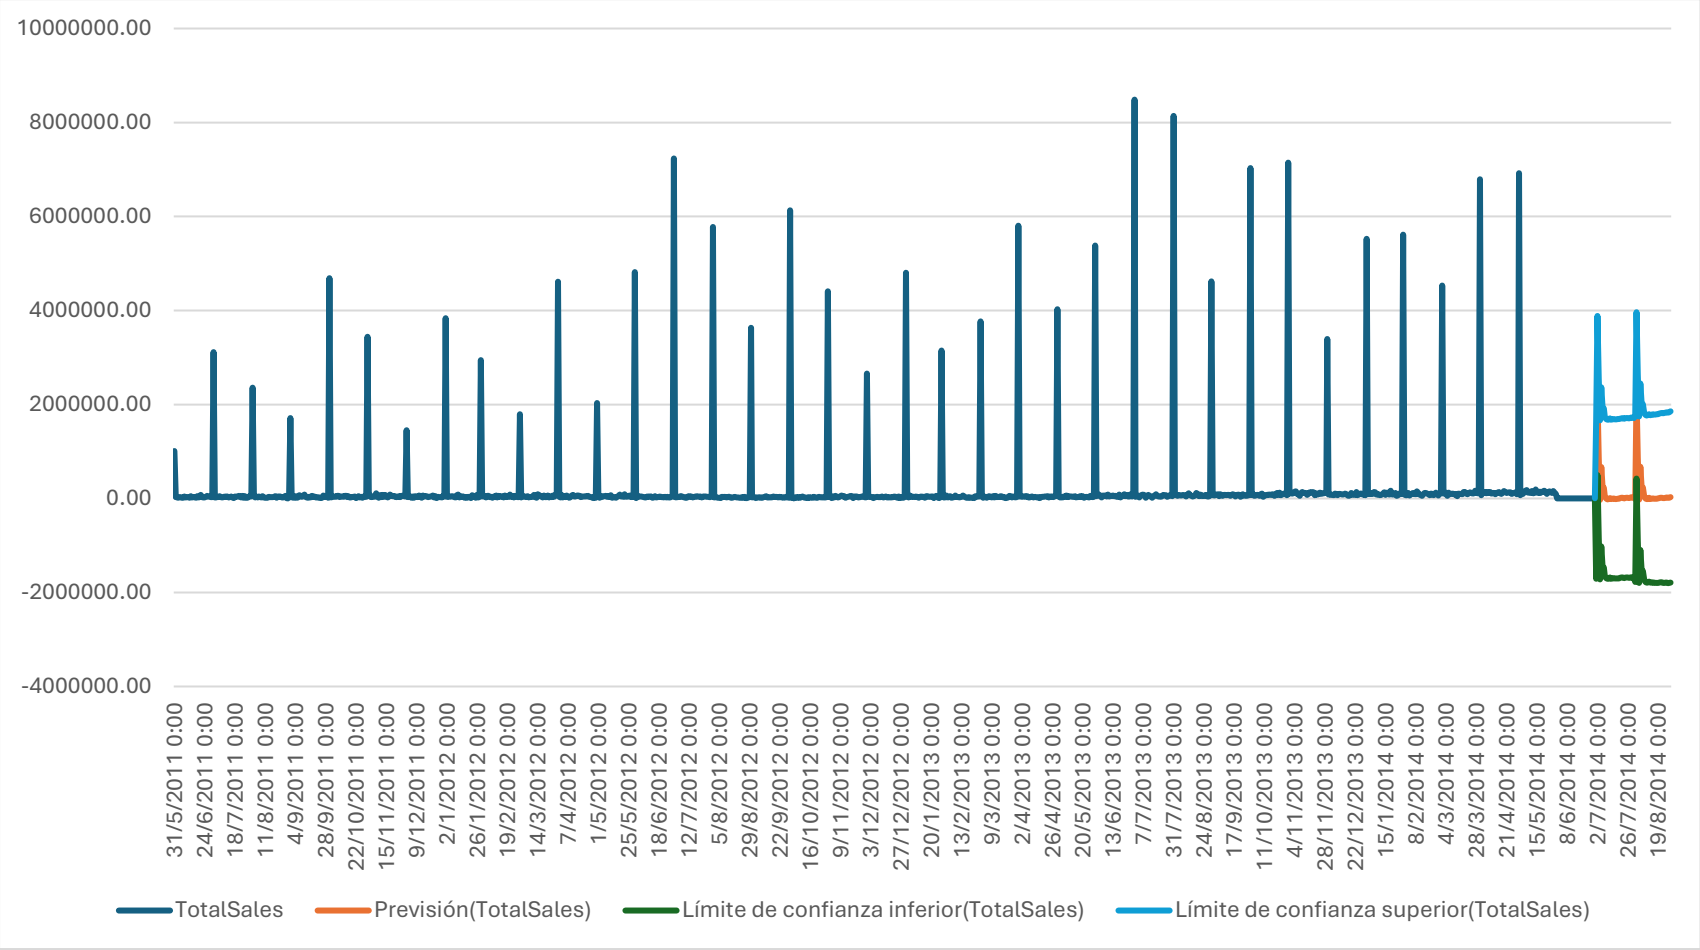

Regresión

Estadísticas de la regresión	
Coeficiente de correlación múltiple	0.74072869
Coeficiente de determinación R^2	0.548678993
R^2 ajustado	0.548581299
Error típico	0.335923791
Observaciones	18484

ANÁLISIS DE VARIANZA

	Grados de libertad	*Suma de cuadrados*	*Promedio de los cuadrados*	*F*	*Valor crítico de F*
Regresión	4	2535.086449	633.7716121	5616.31241	0
Residuos	18479	2085.258931	0.112844793		
Total	18483	4620.34538			

	Coeficientes	*Error típico*	*Estadístico t*	*Probabilidad*	*Inferior 95%*	*Superior 95%*	*Inferior 95.0%*	*Superior 95.0%*
Bike Purchase	0.395432591	0.014106978	28.03099267	2.344E-169	0.367781611	0.42308357	0.367781611	0.42308357
Total amount	0.000168347	1.16685E-06	144.27452	0	0.00016606	0.00017063	0.00016606	0.000170634
Age	-0.001087493	0.00025697	-4.231993236	2.3275E-05	-0.001591177	-0.00058381	-0.001591177	-0.000583809
Total Children	-0.007813885	0.001829305	-4.271503877	1.9513E-05	-0.011399493	-0.00422828	-0.011399493	-0.004228278
Number Cars Owned	-0.060445404	0.002255901	-26.79435412	3.433E-155	-0.064867178	-0.05602363	-0.064867178	-0.05602363

Tabla K Means

Cluster	Z_Total	Z_Age	Z_Children	Z_Cars	Dist_C1	Dist_C2	Dist_C3	Cluster asignado	Nuevo Z_Total	Nuevo Z_Age	Nuevo Z_Children	Nuevo Z_Cars
C1	2.075630459	-0.39293136	1.95715577	-1.32005794	0	3.30791529	4.09651066	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C2	-0.710558097	1.02943206	1.336948545	-0.44160348	0.62035726	3.26095943	3.65601699	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C3	0.360917087	-1.45970392	-1.143880357	0.43685097	1.92509433	2.5599463	2.65193099	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C4	-0.721856605	1.65171606	1.336948545	0.43685097	0.62022167	3.25288304	3.65157756	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C5	-0.477055596	-0.74852221	-0.523673132	-1.32005794	0.62042593	3.23513959	3.64187691	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C6	-0.721856605	1.9184092	0.096534094	1.31530542	3.75463536	3.06551576	2.09437579	3	1.4623769	-0.595420594	0.854565147	-1.320057936
C7	-0.728918172	0.31825035	1.95715577	-1.32005794	1.5172244	2.18152522	3.23854486	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C8	-0.713858203	0.14045492	-1.143880357	-0.44160348	1.42818085	3.10450372	2.87929094	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C9	-0.72830617	-1.19301078	-1.143880357	0.43685097	1.05282324	2.82599316	3.26099386	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C10	-0.705384322	-0.57072678	1.336948545	-0.44160348	1.04438904	2.83421841	3.26434237	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C11	-0.367940254	-1.28190849	-1.143880357	0.43685097	2.78135442	3.28212783	2.0217655	3	1.4623769	-0.595420594	0.854565147	-1.320057936
C12	-0.493527879	1.74061377	-0.523673132	-1.32005794	1.51862503	2.96094673	2.80302167	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C13	1.599233385	-0.92631764	0.096534094	-1.32005794	2.18870822	2.75402061	2.39734982	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C14	-0.743507371	0.94053435	1.336948545	1.31530542	2.08873615	3.18426829	2.40291738	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C15	0.449412652	-0.57072678	0.096534094	-0.44160348	2.05562394	3.15146632	2.43693253	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C16	-0.745390456	0.49604578	0.716741319	2.19375988	2.74272797	3.130546	2.1078809	3	1.4623769	-0.595420594	0.854565147	-1.320057936
C17	-0.729162973	0.14045492	1.95715577	1.31530542	2.06693123	3.13195644	2.42510235	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C18	-0.654060849	1.38502292	1.336948545	0.43685097	1.97762804	3.07419168	2.56076167	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C19	1.209877569	0.22935264	-0.523673132	1.31530542	1.42381237	2.65927602	3.07711485	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C20	-0.741158223	-0.0373405	1.95715577	0.43685097	1.41662465	2.67216634	3.08270651	1	1.4623769	-0.595420594	0.854565147	-1.320057936
C21	0.936594905	-0.57072678	0.096534094	-0.44160348	0.71555007	3.39535835	3.54749444	1	1.4623769	-0.595420594	0.854565147	-1.320057936